

VMamba: Visual State Space Model

NeurIPS 2024 —— 将 Mamba 引入计算机视觉的开山之作

Captain-Mo

目录

前置模块: Abstract 双语对照	3
1 问题链粗读 (Question Chain —— Rough Reading)	4
1.1 Task —— 任务定义	4
1.2 Motivation —— 研究动机	4
1.3 Problem —— 待解决的核心科学问题	4
1.4 Solution —— 核心解决方案	5
1.5 Results —— 核心实验结果	5
1.6 Limitations —— 局限性	6
1.7 Future —— 未来展望	6
2 结构化精读 (Structured Close Reading)	7
2.1 文献元数据 (Metadata)	7
2.2 论文试图解决什么问题? (技术痛点深度剖析)	7
2.3 核心方法与整体结构 (Methodology Overview)	8
2.4 实验设置与结果详解 (Experimental Protocol & Results)	9
2.5 为何能超越现有方法? —— 核心创新点分析	11
2.6 优势与局限的全面评估 (Strengths & Limitations)	11
2.7 对特定领域的可借鉴点 (概览)	12
3 跨学科基础理论深度剖析 (Interdisciplinary Theoretical Foundations)	13
3.1 信息论视角 (Information Theory)	13
3.2 计算几何视角 (Computational Geometry)	13
3.3 控制论视角 (Control Theory)	14
3.4 计算复杂性视角 (Computational Complexity)	14
3.5 认知科学视角 (Cognitive Science)	14
4 应用场景与跨领域迁移启发 (Applications & Cross-Domain Transfer)	16
4.1 图像分类	16
4.2 目标检测与实例分割	16

目录	2
4.3 语义分割	16
4.4 高分辨率视觉任务	16
4.5 视频理解	16
4.6 对高效视觉骨干设计的通用启示	16
总结与批判性思考	17

前置模块：Abstract 双语对照 (English-Chinese Parallel Text)

英文原文 (English Original):

Designing computationally efficient network architectures remains an ongoing necessity in computer vision. In this paper, we adapt Mamba, a state-space language model, into VMamba, a vision backbone with linear time complexity. At the core of VMamba is a stack of Visual State-Space (VSS) blocks with the 2D Selective Scan (SS2D) module. By traversing along four scanning routes, SS2D bridges the gap between the ordered nature of 1D selective scan and the non-sequential structure of 2D vision data, which facilitates the collection of contextual information from various sources and perspectives. Based on the VSS blocks, we develop a family of VMamba architectures and accelerate them through a succession of architectural and implementation enhancements. Extensive experiments demonstrate VMamba's promising performance across diverse visual perception tasks, highlighting its superior input scaling efficiency compared to existing benchmark models.

中文翻译 (Chinese Translation):

设计计算高效的网络架构仍然是计算机视觉中的持续需求。在本文中，我们将状态空间语言模型 Mamba 改造为 VMamba，一个具有线性时间复杂度的视觉骨干网络。VMamba 的核心是堆叠的视觉状态空间 (VSS) 块，其中包含 2D 选择性扫描 (SS2D) 模块。通过沿四条扫描路径遍历，SS2D 弥合了 1D 选择性扫描的有序性与 2D 视觉数据的非序列结构之间的差距，促进了从不同来源和视角收集上下文信息。基于 VSS 块，我们开发了一系列 VMamba 架构，并通过一系列架构和实现上的改进对其进行了加速。大量实验表明，VMamba 在多种视觉感知任务上具有优异的性能，突显了其与现有基准模型相比优越的输入缩放效率。

第1部分 问题链粗读 (Question Chain —Rough Reading)

本部分遵循 $TASK \rightarrow MOTIVATION \rightarrow PROBLEM \rightarrow SOLUTION \rightarrow RESULTS \rightarrow LIMITATIONS \rightarrow FUTURE$ 的问题链, 旨在用最精炼的语言勾勒论文的核心逻辑骨架。

1.1 Task ——任务定义

高效的视觉骨干网络设计 (Efficient Visual Backbone Design): 为计算机视觉任务 (图像分类、目标检测、语义分割等) 设计一个具有线性时间复杂度的骨干网络, 要求:

1. 在 ImageNet 分类上达到或超越 Swin Transformer、ConvNeXt 等 SOTA 模型;
2. 在下游任务 (检测、分割) 上表现优异;
3. 随着输入分辨率增大, 计算复杂度呈**线性增长**而非二次增长;
4. 推理速度高效, 适合实际部署。

1.2 Motivation ——研究动机

1. Transformer 的“效率困境”:

- ViT 等模型的自注意力机制具有全局感受野和动态权重, 但 $O(L^2)$ 复杂度在高分辨率下不可承受。
- Swin 等通过窗口注意力降低复杂度, 但牺牲了全局感受野。

2. Mamba 在 NLP 中的成功:

- Mamba (选择性状态空间模型) 在语言建模上达到 Transformer 质量, 同时具有 $O(L)$ 复杂度。
- 其核心是 1D 选择性扫描, 专为序列数据设计。

3. **核心问题:** 能否将 Mamba 的选择性 SSM 扩展到 2D 视觉数据, 同时保持其线性复杂度和全局感受野?

1.3 Problem ——待解决的核心科学问题

如何将 1D 选择性状态空间模型适配到 2D 视觉数据, 使其能够:

1. 捕获 2D 空间中的全局上下文信息;
2. 保持线性时间复杂度;
3. 在图像分类、检测、分割等视觉任务上达到 SOTA;
4. 在推理速度上优于 Transformer 基线。

1.4 Solution ——核心解决方案

VMamba: 视觉状态空间模型

1. 2D 选择性扫描 (SS2D) (Sec. 4.2, 图 2):

- **Cross-Scan**: 将 2D 特征图沿四条路径展平为 1D 序列:
 - (a) 从左到右, 从上到下
 - (b) 从右到左, 从上到下
 - (c) 从上到下, 从左到右
 - (d) 从下到上, 从左到右
- **选择性扫描**: 四条路径分别通过独立的 S6 块 (Mamba 的选择性 SSM) 处理。
- **Cross-Merge**: 将四条路径的输出合并为 2D 特征图。
- 每个像素从四个方向整合上下文信息, 建立全局感受野。

2. VSS 块 (Visual State-Space Block) (图 3):

- 将 Mamba 块中的 S6 模块替换为 SS2D。
- 移除乘法分支 (门控机制), 因为 SS2D 的选择性已提供类似功能。
- 引入 FFN 层以增强表达能力。

3. 加速优化 (Sec. 4.3, 表 5):

- (a) Triton 重实现 Cross-Scan/Cross-Merge (+41 img/s)
- (b) 调整 CUDA 实现支持 float16 输入 (训练吞吐 165 $\rightarrow$ 184)
- (c) 用线性变换替换 einsum (+174 img/s)
- (d) 优化层配置和超参数 (ssm-ratio、d_state 等)
- (e) 最终吞吐从 426 提升到 1686 img/s

4. 层次化架构 (图 3a):

- 4 个阶段, 分辨率 $H/4 \rightarrow H/8 \rightarrow H/16 \rightarrow H/32$
- 无额外位置编码 (SS2D 通过扫描路径隐式编码空间信息)

1.5 Results ——核心实验结果

1. ImageNet 分类 (表 1):

- VMamba-T: 82.6% (+1.3% vs Swin-T, +2.8% vs DeiT-S)
- VMamba-B: 83.9% (+0.4% vs Swin-B, 吞吐 646 vs 458)
- 吞吐量: VMamba-T 1686 img/s, Swin-T 1244 img/s

2. COCO 目标检测 (表 2):

- 1× 调度: VMamba-T 47.3 AP (+4.6 vs Swin-T, +3.1 vs ConvNeXt-T)
- 3× MS: VMamba-B 51.0 AP (+2.9 vs Swin-B)

3. ADE20K 语义分割 (表 2):

- VMamba-T: 48.0 mIoU (+3.5 vs Swin-T, +2.0 vs ConvNeXt-T)
- VMamba-B: 51.0 mIoU (+2.9 vs Swin-B)

4. 输入缩放效率 (图 4-5, 表 9):

- 分辨率 224 → 768: VMamba 性能下降最小 (82.6% → 74.7%)
- FLOPs 线性增长 (与 CNN 相当), 而 Transformer 二次增长
- 吞吐量保持较高水平 (149 img/s @ 768×768 vs Swin 53 img/s)

5. 有效感受野 (ERF) (图 7):

- VMamba 具有全局、均匀的 2D 感受野
- 与 DeiT、HiViT 类似, 但复杂度线性而非二次

1.6 Limitations ——局限性

1. 无监督预训练未探索: SSM 架构与现有预训练方法的兼容性尚不明确。
2. 计算资源限制: 未探索 Large 规模架构和细粒度超参数搜索。
3. 更通用的扫描模式: SS2D 的四路扫描可能不是最优的 2D 扩展方式。
4. 依赖自定义 CUDA 核: 加速实现依赖 Triton/CUDA, 限制了可移植性。

1.7 Future ——未来展望

1. 探索针对 SSM 架构的自监督预训练方法。
2. 扩展到更大规模 (Large/XL) 和更长序列。
3. 提出更通用的 2D 扫描模式。
4. 将 VMamba 应用到更多视觉任务 (视频理解、3D 感知等)。

第2部分 结构化精读 (Structured Close Reading)

本部分从 8 个维度对论文进行逐层深入的剖析，涵盖文献元数据、方法论、实验与理论启示。

2.1 文献元数据 (Metadata)

- **标题:** VMamba: Visual State Space Model
- **作者:** Yue Liu, Yunjie Tian, Yuzhong Zhao, Hongtian Yu, Lingxi Xie, Yaowei Wang, Qixiang Ye, Jianbin Jiao, Yunfan Liu (UCAS / Huawei / Pengcheng Lab)
- **发表会议:** NeurIPS 2024
- **核心贡献:**
 1. 首次将 Mamba (选择性 SSM) 适配到计算机视觉，提出 **VMamba**。
 2. 提出 **2D 选择性扫描 (SS2D)**，通过四条扫描路径将 1D 选择性扫描扩展到 2D 空间。
 3. 通过架构和实现优化，将推理速度从 426 提升到 1686 img/s (4× 加速)。
 4. 在分类、检测、分割上达到 SOTA，且复杂度线性增长。
- **领域定位:** 计算机视觉 / 骨干网络 / 状态空间模型 / 高效架构
- **影响力:** 首个将 Mamba 成功应用于视觉的工作，后续引出了一系列“视觉 Mamba”研究 (Vim、LocalMamba、EfficientVMamba 等)。

2.2 论文试图解决什么问题？(技术痛点深度剖析)

痛点一：Transformer 的“二次复杂度”

- 自注意力机制虽然强大 (全局感受野、动态权重)，但 $O(L^2)$ 复杂度限制了高分辨率输入。
- 窗口注意力 (Swin) 降低复杂度但牺牲全局感受野。
- 需要一种既有全局感受野又有线性复杂度的架构。

痛点二：SSM 的“1D 局限”

- Mamba 的选择性 SSM 在 NLP 中表现出色，但本质上是为 1D 序列设计的。
- 视觉数据是 2D 的，像素间的关系是空间性的，而非顺序性的。
- 如何将 1D 选择性扫描适配到 2D 空间是一个关键挑战。

痛点三：SSM 在视觉中的“速度问题”

- 直接应用 Mamba 的扫描操作到 2D 数据效率低下。
- 需要硬件感知的优化 (Triton/CUDA) 才能达到实用速度。

2.3 核心方法与整体结构 (Methodology Overview)**3.1 SS2D：2D 选择性扫描 (Sec. 4.2, 图 2)**

三步流程：

1. Cross-Scan (四路扫描)：

$$\text{paths} = \{\text{L2R-T2B}, \text{R2L-T2B}, \text{T2B-L2R}, \text{B2T-L2R}\}$$

将 2D 特征图 $F \in \mathbb{R}^{H \times W \times C}$ 展平为四条 1D 序列。

- 2. 选择性扫描 (S6 块)：** 每条路径独立通过 Mamba 的 S6 模块处理。
- 3. Cross-Merge：** 将四条路径的输出按对应位置相加/平均，重建 2D 特征图。

设计动机：

- 单一路径只能捕获单向上下文（类似因果注意力）。
- 四路互补扫描使每个像素能整合来自四个方向的信息。
- 等价于在 2D 空间上建立“全连接”的感受野。

3.2 VSS 块 (图 3)

原始 Mamba 块：

$$x' = \text{Linear}(x), \quad z = \text{SiLU}(\text{Linear}(x)), \quad y = \text{S6}(x'), \quad \text{out} = z \odot y$$

VSS 块 (改进版)：

$$x' = \text{Linear}(x), \quad y = \text{SS2D}(x'), \quad \text{out} = \text{FFN}(y)$$

改进点：

1. 移除乘法分支（门控）——SS2D 的选择性已提供类似功能。
2. 引入 FFN 层增强表达能力。
3. 更简洁、更快的单分支结构。

表 1: VMamba 加速步骤汇总 (表 5)

步骤	修改	TP (img/s)	Top-1
Vanilla	基线	426	82.17%
(a)	Triton 重实现 Cross-Scan	467	82.17%
(b)	CUDA float16 支持	464	82.17%
(c)	线性变换替换 einsum	638	82.17%
(d)	引入 MLP, 调整层数	813	81.65%
(e)	ssm-ratio 1.0, 移除乘法分支	1179	82.17%
(f)	重新引入 DWConv	1340	82.49%
(g)	ssm-ratio 1.0, 层数 [2,2,8,2]	1686	82.60%

3.3 加速优化 (Sec. 4.3, 表 5)

2.4 实验设置与结果详解 (Experimental Protocol & Results)

数据集与评估

- **ImageNet-1K**: 128 万训练图像, 1000 类。
- **COCO 2017**: 118K 训练, 5K 验证, 目标检测 + 实例分割。
- **ADE20K**: 20K 训练, 2K 验证, 语义分割 (150 类)。
- **指标**: Top-1 准确率 (分类), AP (检测), mIoU (分割)。

定量结果

表 2: ImageNet-1K 分类对比 (表 1 简化)

模型	参数 (M)	FLOPs (G)	TP (img/s)	Top-1
Swin-T	28	4.5	1244	81.3%
ConvNeXt-T	29	4.5	119	82.1%
DeiT-S	22	4.6	176	79.8%
VMamba-T	30	4.9	1686	82.6%
Swin-B	88	15.4	458	83.5%
ConvNeXt-B	89	15.4	436	83.8%
DeiT-B	86	17.5	503	81.8%
VMamba-B	89	15.4	646	83.9%

关键发现

1. **输入缩放效率** (图 4-5, 表 9):

表 3: COCO 目标检测 (1× 调度, 表 2 简化)

骨干	AP ^b	AP ^m
Swin-T	42.7	39.3
ConvNeXt-T	44.2	40.1
VMamba-T	47.3	42.7
Swin-B	46.9	42.3
ConvNeXt-B	47.0	42.7
VMamba-B	49.2	44.1

表 4: ADE20K 语义分割 (表 2 简化)

骨干	mIoU (SS)	mIoU (MS)
Swin-T	44.5	45.8
ConvNeXt-T	46.0	46.7
VMamba-T	48.0	48.8
Swin-B	48.1	49.7
ConvNeXt-B	49.1	49.9
VMamba-B	51.0	51.6

- VMamba 的 FLOPs 随分辨率线性增长 (与 CNN 相当)。
- Swin 的 FLOPs 也线性增长 (窗口注意力), 但需要调整窗口大小。
- DeiT 的 FLOPs 二次增长, 高分辨率下不可行。

2. 有效感受野 (ERF) (图 7):

- VMamba 具有全局、均匀的 2D 感受野。
- Swin 和 ConvNeXt 的 ERF 局部。
- Vim 虽有全局 ERF 但不均匀 (偏向扫描方向)。

3. 扫描模式对比 (图 8, 表 10):

- Cross-Scan (四路) 优于 Unidi-Scan (单路)、Bidi-Scan (两路)、Cascade-Scan (串行两路)。
- Cascade-Scan 速度慢 (不支持并行), Cross-Scan 速度和精度最佳。

4. SS2D 与自注意力的关系 (Sec. 5.3):

- SS2D 的输出可写成类似自注意力的形式:

$$\mathbf{Y}^{(j)} = [\mathbf{Q} \odot \mathbf{w}^{(j)}] \mathbf{h}_a^{(j)} + [(\mathbf{Q} \odot \mathbf{w}^{(j)})(\mathbf{K}/\mathbf{w}^{(j)})^\top \odot \mathbf{M}] \mathbf{V}^{(j)}$$

- $\mathbf{w}$ 是累积注意力权重, $\mathbf{M}$ 是时间掩码。
- SS2D 可理解为带时间衰减的“因果注意力”。

2.5 为何能超越现有方法？——核心创新点分析

表 5: VMamba 与主流视觉骨干的对比

对比维度	CNN (ConvNeXt)	ViT (Swin)	VMamba (本文)
感受野	局部 (堆叠扩大)	窗口局部	全局
复杂度	$O(L)$	$O(L)$ (窗口)	$O(L)$
动态权重	×	✓	✓
内容感知	×	✓	✓ (选择性)
2D 先验	强 (卷积)	强 (窗口)	弱 (扫描路径)
吞吐量	中	中	高

本质原因:

1. **SS2D 的四路扫描**: 通过互补的扫描路径, 在 2D 空间上近似全连接感受野, 同时保持线性复杂度。
2. **选择机制的内容感知**: 继承 Mamba 的选择性 SSM, 参数依赖输入, 实现基于内容的推理。
3. **硬件感知优化**: Triton + CUDA 优化使 SS2D 在 GPU 上高效运行, 吞吐量远超同类模型。
4. **简化的 VSS 块**: 移除门控分支, 引入 FFN, 更简洁高效。

2.6 优势与局限的全面评估 (Strengths & Limitations)

核心优势

- **全局感受野 + 线性复杂度**: 兼具 Transformer 和 CNN 的优点。
- **输入缩放效率**: 高分辨率下性能下降最小, FLOPs 线性增长。
- **吞吐量高**: VMamba-T 1686 img/s, 远超 Swin-T (1244)。
- **下游任务表现优异**: 检测、分割上显著超越 Swin 和 ConvNeXt。
- **ERF 全局均匀**: 比 Vim 更 2D-aware。

局限性

- **依赖自定义 CUDA 核**: Triton 实现限制了在其他硬件上的部署。
- **超参数敏感**: `ssm-ratio`、`d_state` 等需要精细调优 (附录 H)。
- **无监督预训练未探索**: 与现有 MAE、DINO 等方法的兼容性未知。
- **扫描模式的启发式设计**: 四路扫描未必是最优的 2D 扩展方式。

2.7 对特定领域的可借鉴点 (概览)

- **图像分类**: VMamba 可作为高效的分类骨干。
- **目标检测**: 在 COCO 上显著优于 Swin 和 ConvNeXt。
- **语义分割**: ADE20K 上达到 SOTA。
- **高分辨率任务**: 医疗影像、遥感等需要处理大分辨率图像的任务。
- **方法论启示**:
 - “1D 扫描可通过多路径扩展到 2D” ——互补路径近似全连接感受野。
 - “选择机制在视觉中同样有效” ——内容感知的 SSM 在视觉任务上表现优异。
 - “硬件-算法协同设计” ——Triton 加速是实现实用速度的关键。

第3部分 跨学科基础理论深度剖析 (Interdisciplinary Theoretical Foundations)

本部分独立成章，从信息论、计算几何、控制论、计算复杂性和认知科学五个维度进行系统性拆解。

3.1 信息论视角 (Information Theory)

四路扫描的信息冗余：

- 单路扫描： $I(\text{输出}; \text{所有输入}) = I(\text{输出}; \text{仅单向上下文})$ 。
- 四路扫描： $I_{\text{四路}} = I_{\text{左} \rightarrow \text{右}} + I_{\text{右} \rightarrow \text{左}} + I_{\text{上} \rightarrow \text{下}} + I_{\text{下} \rightarrow \text{上}}$ 。
- 互补路径捕获不同方向的信息，减少“信息盲区”。

选择机制的信息选择：

- Mamba 的选择机制根据输入内容决定信息传播。
- 在视觉中，这允许模型“关注”重要区域，“忽略”背景/噪声。
- 等价于在空间维度上进行内容自适应的信息过滤。

状态压缩的信息瓶颈：

- SSM 的状态 h_t 是历史的压缩表示。
- 四路扫描相当于从四个方向分别压缩，然后融合。
- 融合后的状态包含更全面的上下文信息。

3.2 计算几何视角 (Computational Geometry)

扫描路径与空间覆盖：

- 单路扫描：覆盖 1D 曲线，信息沿路径传播。
- 四路扫描：覆盖 2D 平面的四个主方向，任意两点间存在至少一条路径。
- 任意像素对的信息传递路径长度 $\leq$ 扫描路径长度 ($O(H + W)$)。

扫描顺序与空间连续性：

- 相邻像素在扫描序列中不一定相邻（跨越行边界时）。
- 四路扫描通过不同方向的路径互补，缓解了“空间不连续”问题。
- Cross-Merge 通过加权平均融合四条路径，恢复 2D 结构。

3.3 控制论视角 (Control Theory)

2D SSM 作为“时空系统”：

- 1D SSM: $h_t = A_t h_{t-1} + B_t x_t$ (时间维度的状态演化)。
- 2D SSM (四路扫描)：四个方向的状态并行演化。
- 可视为一个**多方向状态估计器**，从四个方向同时估计 2D 空间的状态。

扫描路径的“因果性”：

- 每条扫描路径是因果的 (只依赖之前的像素)。
- 四路扫描相当于四个因果方向的组合。
- 最终输出是非因果的 (整合了四个方向的因果信息)。

3.4 计算复杂性视角 (Computational Complexity)

SS2D 的复杂度分析：

- 单路选择性扫描: $O(L \cdot D \cdot N)$, $L = H \times W$ 。
- 四路扫描: $4 \times O(L \cdot D \cdot N) = O(4LDN)$ 。
- 常数因子 4, 但仍是**线性复杂度**。
- 相比自注意力 $O(L^2 \cdot D)$, 长序列优势明显。

与窗口注意力的对比：

- Swin 窗口注意力: $O(L \cdot W^2)$ (W 窗口大小), 常数复杂度。
- SS2D: $O(L \cdot D \cdot N)$, N 是状态维度 (通常较小, 如 16)。
- 实际吞吐量: VMamba 1686 img/s vs Swin 1244 img/s。

3.5 认知科学视角 (Cognitive Science)

全局视觉感知的认知类比：

- 人类视觉系统在“一瞥”之间获取全局场景信息 (全局优先处理)。
- SS2D 的四路扫描模拟了这种**快速全局扫描**——从多个方向同时获取信息。

选择性注意的认知类比：

- 人类视觉注意力有选择性地关注显著区域。
- Mamba 的“选择机制”在视觉中允许模型根据内容调整信息流。
- 这比固定权重的卷积更接近人类视觉的**自适应性**。

有效感受野 (ERF) 的认知意义:

- VMamba 的 ERF 全局且均匀。
- 这意味着模型在训练后学会了“同时关注”整个图像。
- 这与人类视觉的“全局场景理解”能力相呼应。

本部分总结：本文融合了信息论（四路扫描的信息冗余与互补、内容自适应的信息过滤、多方向状态融合）、计算几何（扫描路径与 2D 空间覆盖、空间连续性与路径长度）、控制论（多方向状态估计器、因果与非因果的组合）、计算复杂性（线性复杂度、与窗口注意力的对比）和认知科学（全局视觉感知、选择性注意、全局感受野）五大领域的核心理念。

第4部分 应用场景与跨领域迁移启发 (Applications & Cross-Domain Transfer)

本部分独立成章，详细展开 VMamba 的核心思想如何迁移到其他任务与领域。

4.1 图像分类

- VMamba 可作为高效的分类骨干，在 ImageNet 上达到 SOTA。
- **迁移点**：四路扫描 + 选择性 SSM 可替代 ViT/CNN 骨干。

4.2 目标检测与实例分割

- VMamba 在 COCO 上显著优于 Swin 和 ConvNeXt。
- **迁移点**：Mask R-CNN、Cascade R-CNN 等检测框架可直接使用 VMamba 骨干。

4.3 语义分割

- VMamba 在 ADE20K 上达到 SOTA。
- **迁移点**：UperNet、DeepLab 等分割框架可直接使用 VMamba 骨干。

4.4 高分辨率视觉任务

- VMamba 的线性复杂度使其特别适合高分辨率输入。
- **迁移点**：医疗影像 (CT/MRI)、遥感图像、文档图像分析。

4.5 视频理解

- 3D SSM 可扩展到视频时空建模。
- **迁移点**：动作识别、视频分割。

4.6 对高效视觉骨干设计的通用启示

1. “1D 扫描可通过多路径扩展到 2D” —— 互补路径近似全连接感受野。
2. “选择机制在视觉中同样有效” —— 内容感知的 SSM 在视觉任务上表现优异。
3. “硬件-算法协同设计是实现实用速度的关键” —— Triton/CUDA 优化不可或缺。
4. “全局感受野 + 线性复杂度 = 高效视觉骨干” —— 这是未来视觉骨干设计的方向。

总结与批判性思考 (Conclusion & Critical Reflections)

VMamba 是 *NeurIPS 2024* 的重要论文，也是将 Mamba 引入计算机视觉领域的开山之作。它通过 SS2D (四路 2D 选择性扫描) 将 Mamba 的 1D 选择性 SSM 适配到 2D 视觉数据，在保持线性复杂度的同时实现了全局感受野，在 ImageNet 分类、COCO 检测、ADE20K 分割等任务上均达到 SOTA。以下从五个维度展开批判性评估。

批判一：SS2D 是“创新”还是“工程适配”？

- SS2D 的核心思想——将 1D 扫描扩展到 2D——本质上是一个**工程适配**而非基础理论创新。
- 四路扫描的启发式设计（左右、上下四个方向）缺少理论最优性证明。
- 但：
 1. 这是**首次**将 Mamba 成功应用于视觉，并达到 SOTA。
 2. 四路扫描的设计直观有效，实验验证了其优越性。
 3. 后续工作（如 LocalMamba、EfficientVMamba）在此基础上改进，证明其开创性。
- 这类似于 ViT 将 Transformer 从 NLP 迁移到视觉——看似简单，但效果显著。

批判二：VMamba 真的“超越”了 Swin 吗？——公平性考量

- VMamba 在分类、检测、分割上均超越 Swin，但：
 1. VMamba 使用了更先进的训练技术（EMA、drop path 等）。
 2. Swin 是 2021 年的架构，ConvNeXt 是 2022 年的。
 3. 后续工作（如 SwinV2）可能已缩小差距。
- 但 VMamba 的**输入缩放效率**是真正的优势——高分辨率下性能下降最小，这是架构层面的差异。

批判三：加速优化的“工程复杂度”

- VMamba 从 426 img/s 加速到 1686 img/s (4×) ——这是一个巨大的工程成就。
- 但：
 1. 加速依赖 Triton 自定义核，代码复杂，可移植性差。
 2. 不同 GPU 架构可能需要重新优化。
 3. 这与 Swin 的“纯 PyTorch”实现形成对比。
- “算法-硬件协同设计”的代价——效率提升伴随可移植性下降。

批判四：SS2D 的“四路扫描”是否最优？

- 论文比较了 Unidi、Bidi、Cascade、Cross 四种扫描模式，Cross 最优。
- 但：
 1. 四路扫描的排列组合空间很大（8 个方向，多种顺序）。
 2. 是否有五路、六路或自适应扫描能进一步提升？
 3. 后续工作（如 LocalMamba）提出了局部扫描，证明还有改进空间。
- Cross-Scan 是“足够好”的启发式设计，但未必是“最优”的。

批判五：VMamba 的“语言-视觉迁移”是否可逆？

- 论文将 Mamba 从 NLP 迁移到视觉，效果显著。
- 但：
 1. 视觉中是否有新的机制可以反馈给 NLP？
 2. 四路扫描的思想能否用于多文档/多模态的 1D 序列？
 3. 目前尚未探索“视觉 Mamba”反哺“语言 Mamba”的可能性。
- 这为未来研究留下了开放问题。

结语：从“语言 SSM”到“视觉 SSM”的范式迁移

VMamba 的核心哲学是：

1. **1D 扫描可通过多路径扩展到 2D**：互补扫描路径可近似全连接感受野。
2. **选择机制在视觉中同样有效**：内容感知的 SSM 在视觉任务上表现优异。
3. **硬件-算法协同设计是实现实用速度的关键**：Triton 加速是 VMamba 成功部署的关键。
4. **线性复杂度并不等于“弱能力”**：VMamba 证明线性时间模型可以在视觉上达到 SOTA。

读懂 VMamba，是为了理解：Mamba 不仅是 NLP 的突破，也可以成为视觉的基石。通过巧妙的 2D 适配（四路扫描）和硬件感知优化，SSM 的线性复杂度优势在视觉任务上得到了充分发挥。VMamba 告诉我们：在架构设计中，“迁移”有时比“发明”更有价值——将一个领域成功的范式适配到另一个领域，可能产生意想不到的突破。