

RWKV: Reinventing RNNs for the Transformer Era

ICLR 2025 ——结合 Transformer 训练效率与 RNN 推理效率的新型架构

Captain-Mo

目录

前置模块：Abstract 双语对照	3
1 问题链粗读 (Question Chain ——Rough Reading)	4
1.1 Task ——任务定义	4
1.2 Motivation ——研究动机	4
1.3 Problem ——待解决的核心科学问题	4
1.4 Solution ——核心解决方案	5
1.5 Results ——核心实验结果	6
1.6 Limitations ——局限性	6
1.7 Future ——未来展望	7
2 结构化精读 (Structured Close Reading)	8
2.1 文献元数据 (Metadata)	8
2.2 论文试图解决什么问题? (技术痛点深度剖析)	8
2.3 核心方法与整体结构 (Methodology Overview)	9
2.4 实验设置与结果详解 (Experimental Protocol & Results)	10
2.5 为何能超越现有方法? ——核心创新点分析	11
2.6 优势与局限的全面评估 (Strengths & Limitations)	12
2.7 对特定领域的可借鉴点 (概览)	12
3 跨学科基础理论深度剖析 (Interdisciplinary Theoretical Foundations)	13
3.1 信息论视角 (Information Theory)	13
3.2 动力系统视角 (Dynamical Systems)	13
3.3 计算复杂性视角 (Computational Complexity)	14
3.4 优化理论视角 (Optimization Theory)	14
3.5 控制论视角 (Control Theory)	15
4 应用场景与跨领域迁移启发 (Applications & Cross-Domain Transfer)	16
4.1 大语言模型部署	16
4.2 序列建模的通用范式	16

目录	2
4.3 编码器-解码器架构	16
4.4 对高效架构设计的通用启示	16
总结与批判性思考	17

前置模块：Abstract 双语对照 (English-Chinese Parallel Text)

英文原文 (English Original):

Transformers have revolutionized almost all natural language processing (NLP) tasks but suffer from memory and computational complexity that scales quadratically with sequence length. In contrast, recurrent neural networks (RNNs) exhibit linear scaling in memory and computational requirements but struggle to match the same performance as Transformers due to limitations in parallelization and scalability. We propose a novel model architecture, Receptance Weighted Key Value (RWKV), that combines the efficient parallelizable training of transformers with the efficient inference of RNNs. Our approach leverages a linear attention mechanism and allows us to formulate the model as either a Transformer or an RNN, thus parallelizing computations during training and maintains constant computational and memory complexity during inference. We scale our models as large as 14 billion parameters, by far the largest dense RNN ever trained, and find RWKV performs on par with similarly sized Transformers, suggesting future work can leverage this architecture to create more efficient models. This work presents a significant step towards reconciling trade-offs between computational efficiency and model performance in sequence processing tasks.

中文翻译 (Chinese Translation):

Transformer 几乎革新了所有自然语言处理任务，但存在随序列长度呈平方增长的内存和计算复杂度。相比之下，循环神经网络在内存和计算需求上呈线性扩展，但由于并行化和可扩展性的限制，难以达到与 Transformer 相同的性能。我们提出了一种新颖的模型架构——Receptance Weighted Key Value (RWKV)，它结合了 Transformer 的高效可并行训练和 RNN 的高效推理。我们的方法利用线性注意力机制，使我们能够将模型表述为 Transformer 或 RNN，从而在训练期间实现计算并行化，并在推理期间保持恒定计算和内存复杂度。我们将模型扩展到 140 亿参数，这是迄今为止训练过的最大密集 RNN，并发现 RWKV 的性能与同等规模的 Transformer 相当，这表明未来的工作可以利用这种架构创建更高效的模型。这项工作在序列处理任务中协调计算效率和模型性能之间的权衡方面迈出了重要一步。

第1部分 问题链粗读 (Question Chain —Rough Reading)

本部分遵循 $TASK \rightarrow MOTIVATION \rightarrow PROBLEM \rightarrow SOLUTION \rightarrow RESULTS \rightarrow LIMITATIONS \rightarrow FUTURE$ 的问题链, 旨在用最精炼的语言勾勒论文的核心逻辑骨架。

1.1 Task ——任务定义

高效序列建模 (Efficient Sequence Modeling): 设计一种神经网络架构, 能够:

1. 在**训练**时具备 Transformer 的并行化能力 (快速、可扩展);
2. 在**推理**时具备 RNN 的线性复杂度 (低内存、低延迟);
3. 在大规模 (数十亿参数) 下达到与 Transformer 竞争的性能。

1.2 Motivation ——研究动机

1. Transformer 的“推理困境”:

- Transformer 训练高效 (并行), 但推理时需缓存所有 KV 缓存, 复杂度 $O(n)$ 内存、 $O(n^2)$ 计算。
- 长序列 (如 10K+ tokens) 推理成本极高。

2. RNN 的“训练困境”:

- RNN (LSTM、GRU) 推理高效 ($O(1)$ 状态, $O(n)$ 计算)。
- 但训练时无法并行化 (时间维度的顺序依赖), 难以扩展到数十亿参数。

3. **核心问题:** 能否设计一个架构, 同时具备 Transformer 的训练并行性和 RNN 的推理高效性?

1.3 Problem ——待解决的核心科学问题

如何设计一个序列模型, 能够:

1. 在训练时使用**并行矩阵乘法** (类似 Transformer);
2. 在推理时使用**恒定大小状态** (类似 RNN);
3. 达到与 Transformer 竞争的语言建模性能;
4. 扩展到 140 亿参数以上。

1.4 Solution ——核心解决方案

RWKV: Receptance Weighted Key Value

1. 核心思想 (Sec. 3, 图 2):

- 使用**线性注意力**替代 Transformer 的二次自注意力。
- 将注意力公式修改为可递归计算的形式, 使其在推理时可转换为 RNN。

2. 四个核心元素:

- (a) **R (Receptance)**: 接收过去信息的向量。
- (b) **W (Weight)**: 位置权重衰减向量 (可训练)。
- (c) **K (Key)**: 类似传统注意力中的 K。
- (d) **V (Value)**: 类似传统注意力中的 V。

3. 时间混合 (Time-Mixing) 公式 (Sec. 3.1.2):

$$wkv_t = \frac{\sum_{i=1}^{t-1} e^{-(t-1-i)w+k_i} \odot v_i + e^{u+k_t} \odot v_t}{\sum_{i=1}^{t-1} e^{-(t-1-i)w+k_i} + e^{u+k_t}}$$

- w : 通道级时间衰减向量 ($w \in \mathbb{R}_{\geq 0}^d$)。
- u : 当前 token 的“奖励”向量。
- 可递归计算 (Sec. 3.3), 转换为 RNN 状态。

4. Token Shift (Sec. 3.1.1):

- 每个线性投影使用当前和前一时刻输入的线性插值。
- $r_t = W_r \cdot (\mu_r \odot x_t + (1 - \mu_r) \odot x_{t-1})$
- 实现: `nn.ZeroPad2d((0,0,1,-1))` 的简单偏移。

5. 输出门控 (Sec. 3.1.3):

- $o_t = W_o \cdot (\sigma(r_t) \odot wkv_t)$
- 通道混合: $o'_t = \sigma(r'_t) \odot (W'_v \cdot \max(k'_t, 0)^2)$ (Squared ReLU)

6. 两种模式 (Sec. 3.2-3.3):

- **训练模式 (Time-Parallel)**: 类似 Transformer, 矩阵乘法并行。
- **推理模式 (Time-Sequential)**: 类似 RNN, $O(1)$ 状态递归更新。

7. RNN 状态 (Sec. D):

$$a_t = e^{-w} \odot a_{t-1} + e^{k_t} \odot v_t, \quad b_t = e^{-w} \odot b_{t-1} + e^{k_t}$$

$$wkv_t = \frac{a_{t-1} + e^{u+k_t} \odot v_t}{b_{t-1} + e^{u+k_t}}$$

1.5 Results ——核心实验结果

1. 模型规模 (表 2):

- 训练 6 个模型: 169M、430M、1.5B、3B、7B、14B 参数。
- 在 Pile (330B tokens) 上训练 1 epoch。
- 14B 参数——迄今为止最大的密集 RNN。

2. 缩放定律 (图 4):

- RWKV 遵循与 Transformer 相同的幂律缩放。
- $r^2 = 0.994$ (Pareto 最优拟合)。
- 外推一个数量级后 $r^2 = 0.875$ 。

3. NLP 基准 (图 1, 图 5, 图 12):

- 在 ARC、BoolQ、COPA、HellaSwag、LAMBADA、PIQA、Winogrande 等 12 个任务上与 Pythia、OPT、BLOOM 同等规模模型**相当**。
- 平均性能略优于同等规模的 Transformer (图 1)。

4. 长上下文 (图 6):

- 从 1024 逐步微调到 8192 上下文长度。
- 测试损失随上下文长度增加而降低——RWKV 能有效利用长上下文。

5. Long Range Arena (表 4):

- 在 5 个数据集上仅次于 S4 模型。
- 在文本和代码相关任务上与 S4 相当。

6. 推理效率 (图 7, 13-14):

- 推理时间随序列长度**线性**增长 (Transformer 为平方增长)。
- 内存占用恒定 (与序列长度无关)。

1.6 Limitations ——局限性

1. 线性注意力的信息瓶颈:

- 信息通过单向量表示“漏斗”传播, 无法像 Transformer 那样保留全序列信息。
- 长上下文中“回头看”能力有限。

2. 对提示工程敏感 (附录 L):

- RNN 无法“回头看”调整先前信息权重。
- 提示中信息顺序影响极大 (F1 从 44.2% 升至 74.8%)。

3. 数学推理能力弱:

- MathQA 上仅 5.43% (ChatGPT 71.4%)。
- 难以处理需要中间结果的推理任务。

4. 仍需定制 CUDA 核:

- WKV 计算的顺序性需要自定义 CUDA 核优化。

1.7 Future ——未来展望

1. 增强时间衰减公式, 提高模型表现力。
2. 使用并行扫描 (parallel scan) 将 WKV 计算降至 $O(B \log(T)d)$ 。
3. 将 RWKV 应用于编码器-解码器架构 (seq2seq、多模态)。
4. 利用 RWKV 状态进行可解释性、安全性和行为引导。
5. 增大内部状态, 增强模型对长上下文的记忆。

第2部分 结构化精读 (Structured Close Reading)

本部分从 8 个维度对论文进行逐层深入的剖析，涵盖文献元数据、方法论、实验与理论启示。

2.1 文献元数据 (Metadata)

- **标题:** RWKV: Reinventing RNNs for the Transformer Era
- **作者:** Bo Peng 等 (Generative AI Commons、EleutherAI、多所大学/公司)
- **发表会议:** ICLR 2025
- **核心贡献:**
 1. 提出 **RWKV** 架构，首次将 RNN 扩展到 140 亿参数。
 2. 结合 Transformer 的训练并行性和 RNN 的推理高效性。
 3. 证明 RNN 也可遵循 Transformer 的缩放定律。
 4. 开源从 169M 到 14B 的预训练模型，推动社区研究。
- **领域定位:** 深度学习 / 语言模型 / RNN / 注意力机制 / 高效架构
- **影响力:** 首次成功挑战 Transformer 在大规模语言建模中的主导地位，开辟了“RNN 复兴”的新方向。

2.2 论文试图解决什么问题？(技术痛点深度剖析)

痛点一：Transformer 的“推理诅咒”

- Transformer 训练时高效（并行），但推理时：
 1. 需缓存所有历史 token 的 K、V ($O(n)$ 内存)。
 2. 每个新 token 需与所有历史 token 计算注意力 ($O(n^2)$ 计算)。
- 长序列（如 10K tokens）推理成本极高，限制了部署。

痛点二：RNN 的“训练诅咒”

- RNN 推理高效 ($O(1)$ 状态, $O(n)$ 计算)。
- 但训练时：
 1. 时间维度的顺序依赖禁止并行化（需逐 token 传播）。
 2. 梯度消失/爆炸问题（虽有 LSTM/GRU 缓解，但仍存在）。
- 此前 RNN 从未成功扩展到数十亿参数。

痛点三：现有线性注意力/SSM 的局限

- Linear Transformer、Performer、S4、Mamba 等尝试解决上述问题。
- 但此前没有模型能在**数十亿参数**下与 Transformer 竞争。
- RWKV 是第一个做到这一点的。

2.3 核心方法与整体结构 (Methodology Overview)**3.1 核心公式 (Sec. 3)**

AFT 的启示： Attention Free Transformer [Zhai et al., 2021]:

$$\text{Attn}^+(W, K, V)_t = \frac{\sum_{i=1}^T e^{w_{t,i}+k_i} \odot v_i}{\sum_{i=1}^T e^{w_{t,i}+k_i}}$$

其中 $w_{t,i}$ 是成对位置偏置 ($T \times T$ 矩阵)。

RWKV 的改进： 将 $w_{t,i}$ 替换为**通道级时间衰减**：

$$w_{t,i} = -(t-i)w, \quad w \in \mathbb{R}_{\geq 0}^d$$

使注意力可递归计算。

WKV 算子 (Sec. 3.1.2, Eq. 16):

$$wkv_t = \frac{\sum_{i=1}^{t-1} e^{-(t-1-i)w+k_i} \odot v_i + e^{u+k_t} \odot v_t}{\sum_{i=1}^{t-1} e^{-(t-1-i)w+k_i} + e^{u+k_t}}$$

- e^{-w} : 时间衰减因子 (0 到 1 之间)。
- u : 当前 token 的“奖励”参数。
- 分母是归一化因子 (类似 softmax 的分母)。

3.2 RNN 形式的递归 (Sec. D, Eq. 21-28)

状态更新：

$$a_t = e^{-w} \odot a_{t-1} + e^{k_t} \odot v_t, \quad b_t = e^{-w} \odot b_{t-1} + e^{k_t}$$

$$wkv_t = \frac{a_{t-1} + e^{u+k_t} \odot v_t}{b_{t-1} + e^{u+k_t}}$$

状态组成 (5 部分):

1. 当前时间混合块输入 x_t
2. 当前通道混合块输入 y_t
3. 分子 a'_t (Eq. 26)
4. 分母 b'_t (Eq. 27)
5. 辅助状态 p_t (Eq. 28, 数值稳定性)

总大小: $5DL$ (D 为模型维度, L 为层数)。

3.3 Token Shift (Sec. 3.1.1)

每个线性投影使用当前和前一时刻输入的线性插值：

$$r_t = W_r \cdot (\mu_r \odot x_t + (1 - \mu_r) \odot x_{t-1})$$

$$k_t = W_k \cdot (\mu_k \odot x_t + (1 - \mu_k) \odot x_{t-1})$$

$$v_t = W_v \cdot (\mu_v \odot x_t + (1 - \mu_v) \odot x_{t-1})$$

实现：PyTorch 的 `nn.ZeroPad2d((0,0,1,-1))`。

3.4 训练 vs 推理模式

- **训练 (Time-Parallel)**：所有 r_t, k_t, v_t 可并行计算（矩阵乘法）， WKV 计算需串行扫描但复杂度 $O(BTd)$ 。
- **推理 (Time-Sequential)**：转换为 RNN，每次步进更新状态 $O(1)$ 。

2.4 实验设置与结果详解 (Experimental Protocol & Results)

训练设置

- **数据**：Pile (330B tokens)。
- **模型**：169M 到 14B 参数 (表 2)。
- **优化器**：Adam (无权重衰减)，bfloat16。
- **学习率**：恒定 $\rightarrow$ 指数衰减。
- **上下文**：1024 tokens。

定量结果

表 1: RWKV 模型架构和 FLOPs (表 2)

模型	层数	维度	参数	FLOP/Token
169M	12	768	1.69×10^8	2.61×10^8
430M	24	1024	4.30×10^8	7.57×10^8
1.5B	24	2048	1.52×10^9	2.82×10^9
3B	32	2560	2.99×10^9	5.71×10^9
7B	32	4096	7.39×10^9	1.44×10^{10}
14B	40	5120	1.42×10^{10}	2.78×10^{10}

表 2: Long Range Arena 结果 (表 4 简化)

模型	ListOps	Text	Retrieval	Image	Pathfinder	Avg
Transformer	36.37	64.27	57.46	42.44	71.40	53.66
S4	59.60	86.82	90.90	88.65	94.20	86.09
RWKV	55.88	86.04	88.34	70.53	58.42	72.07

关键发现

- 1. 缩放定律: RWKV 的 loss 与计算量的关系为 $r^2 = 0.994$ (图 4) ——与 Transformer 相同。
- 2. 长上下文微调: 从 1024 → 2048 → 4096 → 8192, 测试损失持续下降 (图 6)。
- 3. 推理效率 (图 7): RWKV 推理时间线性增长, Transformer 平方增长。
- 4. 梯度稳定性 (附录 H): RWKV 的梯度有界, 不会爆炸。
- 5. 提示工程敏感性 (附录 L): 信息顺序对性能影响巨大 (F1 从 44.2% 升至 74.8%)。

2.5 为何能超越现有方法？——核心创新点分析

表 3: RWKV 与 Transformer、RNN 的本质对比

对比维度	Transformer	传统 RNN	RWKV (本文)
训练并行化	✓ (全并行)	× (顺序)	✓ (矩阵乘法)
推理复杂度	$O(n^2)$	$O(n)$	$O(n)$
推理内存	$O(n)$ (KV 缓存)	$O(1)$ (状态)	$O(1)$ (状态)
长距离依赖	✓ (全注意力)	有限 (衰减)	✓ (时间衰减 + U)
大规模 (14B+)	✓	×	✓

本质原因:

- 1. 线性注意力 + 递归形式: 在训练时用矩阵乘法并行计算, 推理时用递归更新——两种模式共享同一套权重。
- 2. 通道级时间衰减: w 向量提供可学习的“遗忘门”, 允许模型在不同通道上以不同速率衰减历史信息。
- 3. Token Shift: 通过当前和前一时刻输入的线性插值, 在每层引入“短期记忆”。
- 4. 数值稳定技巧: 使用共享指数 p_t 避免 e^{k_t} 溢出。

2.6 优势与局限的全面评估 (Strengths & Limitations)

核心优势

- **推理效率**: $O(n)$ 时间, $O(1)$ 状态——理想的长序列部署。
- **训练效率**: 矩阵乘法并行, 与 Transformer 相当。
- **可扩展性**: 首次将 RNN 扩展到 140 亿参数。
- **缩放定律**: 与 Transformer 相同, 可预测。
- **开源**: 多尺寸预训练模型供社区使用。

局限性

- **信息瓶颈**: 单向量状态无法保留全序列信息。
- **提示工程敏感**: RNN 无法“回头看”, 信息顺序重要。
- **数学推理弱**: 需分步计算的任务表现差。
- **自定义 CUDA 核**: WKV 计算需优化实现。

2.7 对特定领域的可借鉴点 (概览)

- **语言模型**: RWKV 可作为 Transformer 的轻量级替代, 尤其适合长文本和低延迟部署。
- **对话系统**: $O(1)$ 状态使 RWKV 适合维护长对话上下文。
- **边缘/移动端部署**: 低内存占用适合资源受限设备。
- **方法论启示**:
 - “线性注意力 + 递归 = 两全其美” ——在训练和推理之间找到平衡。
 - “RNN 也可以遵守缩放定律” ——RNN 并非注定无法扩展。
 - “状态压缩的代价” —— $O(1)$ 状态意味着信息损失, 需谨慎权衡。

第3部分 跨学科基础理论深度剖析 (Interdisciplinary Theoretical Foundations)

本部分独立成章，从信息论、动力系统、计算复杂性、优化理论和控制论五个维度进行系统性拆解。

3.1 信息论视角 (Information Theory)

状态压缩的信息瓶颈：

- RWKV 的 RNN 状态大小为 $O(1)$ (相对序列长度)。
- 这相当于**信息瓶颈**： $I(\text{状态}; \text{全部历史}) \leq \text{状态容量}$ 。
- Transformer 的 KV 缓存大小为 $O(n)$ ，保留全序列信息。
- 这是 RWKV 在需要“回顾细节”的任务上表现较差的根本原因。

通道级时间衰减的信息选择：

- w 向量决定每个通道的历史信息衰减速度。
- 某些通道 w 接近 0 (几乎不衰减) $\rightarrow$ 长期记忆。
- 某些通道 w 很大 (快速衰减) $\rightarrow$ 短期局部信息。
- 这类似于信息论中的**多尺度信息流**。

3.2 动力系统视角 (Dynamical Systems)

RNN 状态作为非线性动力系统：

- RWKV 的状态更新可视为离散时间动力系统：

$$h_t = f(h_{t-1}, x_t; \theta)$$

- 其中 $h_t = (a_t, b_t, p_t)$ ， f 由 Eq. 21-28 定义。
- 时间衰减 $e^{-w} \in (0, 1)$ 确保系统是**有界输入-有界状态** (BIBO 稳定)。

长期依赖与梯度稳定性 (附录 H)：

- RWKV 的梯度有界： $\left| \frac{\partial wkv_T}{\partial W_v} \right| \leq \max_t |(x_t)_j|$ 。
- 这证明了 RWKV 不存在梯度爆炸问题。
- 时间衰减 w 控制梯度衰减速度——不会“消失”到零，除非设计如此。

3.3 计算复杂性视角 (Computational Complexity)

训练复杂度:

- 矩阵乘法部分: $O(BTd^2)$ (与 Transformer 相同)。
- WKV 串行扫描: $O(BTd)$ (比矩阵乘法低一个数量级)。
- 整体: $O(BTd^2)$ ——与 Transformer 相当。

推理复杂度:

- 每个新 token: $O(d^2)$ (矩阵乘法) + $O(d)$ (状态更新)。
- 总时间: $O(Td^2)$ (与序列长度线性)。
- 内存: $O(d)$ (状态大小) ——不随 T 增长。

与 Transformer 的对比:

- Transformer 推理: $O(T^2d)$ 时间, $O(Td)$ 内存。
- RWKV 推理: $O(Td^2)$ 时间, $O(d)$ 内存。
- 当 $d \ll T$ (常见情况), RWKV 显著更优。

3.4 优化理论视角 (Optimization Theory)

初始化策略的重要性 (Sec. 3.4, 附录 F):

- 小初始化嵌入 ($\mathcal{U}(\pm 10^{-4})$) 加速收敛 (图 9)。
- 原因: 梯度在第一层 LayerNorm 后会被放大, 小初始化防止早期梯度爆炸。
- 与 Transformer 中常用的 Xavier/He 初始化不同。

指数衰减学习率:

- 与传统 Transformer 的分段恒定学习率不同。
- 指数衰减使模型在训练结束时更精细地调整。

辅助损失 (Chowdhery et al., 2022):

- 鼓励 softmax 归一化器接近零。
- 帮助稳定 RWKV 的 attention-like 计算。

3.5 控制论视角 (Control Theory)

RWKV 作为 “状态估计器”:

- 时间衰减 e^{-w} 类似于控制理论中的**指数加权移动平均** (EWMA)。
- 状态 (a_t, b_t) 是历史观测的**加权和**，权重随时间指数衰减。
- u 是当前观测的 “增益” ——类似 Kalman 滤波中的**卡尔曼增益**。

反馈控制类比:

- 每层 RWKV 接收当前输入 x_t 和先前状态 h_{t-1} 。
- 输出 o_t 是状态和当前输入的非线性函数。
- 这类似于**反馈控制系统**: 状态反馈 + 前馈控制。

本部分总结: 本文融合了信息论 (状态压缩的信息瓶颈、多尺度信息流)、动力系统 (非线性状态更新、BIBO 稳定性、梯度有界性)、计算复杂性 (训练 $O(BTd^2)$ 与 *Transformer* 相当、推理 $O(Td^2)$ 远优于 *Transformer*)、优化理论 (小初始化嵌入、指数衰减学习率、辅助损失) 和控制论 (EWMA 状态估计、反馈控制系统) 五大领域的核心理念。

第4部分 应用场景与跨领域迁移启发 (Applications & Cross-Domain Transfer)

本部分独立成章，详细展开 RWKV 的核心思想如何迁移到其他任务与领域。

4.1 大语言模型部署

- **长文本推理**：RWKV 的 $O(1)$ 状态使其适合处理超长文档 (10K+ tokens)。
- **边缘/移动端**：低内存占用使其可在资源受限设备上运行。
- **实时对话系统**： $O(1)$ 状态更新适合流式交互。

4.2 序列建模的通用范式

- **时间序列预测**：RWKV 的指数衰减机制适合建模时间序列。
- **音频/语音处理**：线性注意力适合长音序列。
- **视频理解**：可处理长视频帧序列。

4.3 编码器-解码器架构

- RWKV 可替代 seq2seq 中的交叉注意力。
- **迁移点**：解码器状态可编码整个编码器输出。

4.4 对高效架构设计的通用启示

1. “**训练和推理可以有不同的计算图**”——同一模型可在训练时用并行模式，推理时用递归模式。
2. “**线性注意力 + 递归状态 = 两全其美**”——注意力提供表达能力，递归提供效率。
3. “**RNN 也可以遵守缩放定律**”——RNN 并非注定无法扩展，关键在于公式设计。
4. “**信息瓶颈的代价**”—— $O(1)$ 状态意味着无法保留全部历史信息，需根据任务权衡。

总结与批判性思考 (Conclusion & Critical Reflections)

RWKV 是 *ICLR 2025* 的里程碑论文，也是“*RNN* 复兴”运动的标志性成果。它首次将 *RNN* 扩展到 140 亿参数，并在多个 *NLP* 基准上达到与同等规模 *Transformer* 相当的性能，同时推理效率远超 *Transformer*。这项工作的核心贡献不是提出一个“更好的模型”，而是证明了一个被广泛忽视的可能性：*RNN* 并非注定无法扩展。以下从五个维度展开批判性评估。

批判一：RWKV 真的“结合”了 Transformer 和 RNN 的优势吗？

- **训练**：RWKV 的训练并行性来自矩阵乘法，类似 Transformer。
- **推理**：RWKV 的推理效率来自 $O(1)$ 状态，类似 RNN。
- **但**：
 1. RWKV 的“注意力”是线性的，而非 Transformer 的二次注意力——表达能力本质上有上限。
 2. RWKV 无法像 Transformer 那样“回头看”所有历史信息。
 3. 这导致在需要细粒度回忆的任务上（如数学推理），RWKV 表现差。
- RWKV 是“结合”而非“统一”——它在某些方面做了权衡。

批判二：缩放定律——RWKV 真的“遵循”还是“被拟合”？

- 论文声称 RWKV 遵循与 Transformer 相同的缩放定律 ($r^2 = 0.994$)。
- **但**：
 1. 缩放定律的验证依赖于最优超参数的选择——不同模型可能需要不同的最优配置。
 2. 论文仅训练了 6 个模型 (169M-14B)，数据点较少。
 3. 外推一个数量级后 r^2 降至 0.875——拟合质量下降。
- 结论成立，但证据不如 Transformer 的缩放定律研究 (Kaplan et al., Hoffmann et al.) 充分。

批判三：提示工程敏感性——是“特性”还是“缺陷”？

- RWKV 对提示中信息顺序高度敏感 (F1 从 44.2% 升至 74.8%)。
- 原因：RNN 无法“回头看”并重新加权先前信息。
- 这既是：
 1. **缺陷**：需要更精细的提示工程设计，增加了使用难度。

2. **特性**：提示中信息顺序**确实**应该影响模型行为——Transformer 的全注意力可能对顺序不敏感，反而失去了对顺序信息的利用。

- 这值得进一步研究：RNN 的“顺序敏感性”是否是一种**优势**而非缺陷？

批判四：数学推理弱——是 RWKV 的“天花板”吗？

- RWKV 在 MathQA 上仅 5.43% (ChatGPT 71.4%)。
- 原因：
 1. 数学推理需要**多步中间结果**——RNN 的单状态难以同时保留所有中间步骤。
 2. 即使使用 Chain-of-Thought, RWKV 也难以跟踪长推理链。
- 这可能是 RNN 架构的**根本限制**—— $O(1)$ 状态无法编码复杂推理结构。
- 但：可以增大状态大小（如 $O(k)$ 状态）来缓解——这可能是未来方向。

批判五：RWKV 的“后继者”已经出现——Mamba 等 SSM 更强

- RWKV 不是唯一的“Transformer 替代品”。
- 同期/后续工作：
 1. **Mamba** (Gu & Dao, 2023)：基于 SSM，进一步提升了效率和性能。
 2. **Hyena** (Poli et al., 2023)：使用卷积 + 门控。
 3. **Griffin** (De et al., 2024)：结合门控线性 RNN 和局部注意力。
- RWKV 的开创性在于**首次证明了 RNN 可扩展到 14B 并达到 Transformer 级性能**。
- 但 RWKV 可能不是“终极答案”——后续工作可能在其基础上进一步改进。

结语：从“Transformer 独大”到“架构多样性”的回归

RWKV 的核心哲学是：

1. **RNN 并未消亡**：只要公式设计得当，RNN 可以扩展到数十亿参数。
2. **训练和推理可以“双模式”**：同一模型在训练时用并行计算，在推理时用递归计算。
3. **状态压缩的代价是信息损失**： $O(1)$ 状态无法保留全序列信息——这既是效率的来源，也是能力的限制。
4. **缩放定律是架构无关的**：RNN 也遵循与 Transformer 相同的幂律缩放，关键在于模型能否有效利用数据和计算。

读懂 *RWKV*, 是为了理解: 在 “*Transformer* 时代”, *RNN* 并没有退出历史舞台, 而是以新的形式回归。*RWKV* 证明了 “效率” 和 “能力” 并非零和博弈——通过巧妙的公式设计, 一个模型可以同时拥有 *Transformer* 的训练并行性和 *RNN* 的推理高效性。这为未来高效序列模型的设计提供了新的方向: 与其在 *Transformer* 的二次复杂度上 “打补丁”, 不如重新思考 *RNN* 的潜力。